گزارش فاز اول پروژه تحلیل داده

تحلیل سفرهای تاکسی‌های زرد نیویورک (مارس ۲۰۲۳)

نام دانشجو: هلیا خسروی
شماره دانشجویی: ۴۰۲۱۰۰۴۲۹

---

۱ صورت‌بندی مسئله

تعریف مسئله واقعی: فرودگاه بین‌المللی JFK و منطقه پرتراکم منهتن (Manhattan) دو قطب کلیدی جابه‌جایی مسافر در نیویورک هستند که نوسانات زمانی تقاضا و گره‌های ترافیکی، کارایی ناوگان تاکسی‌رانی را به شدت تحت تأثیر قرار می‌دهند. مسئله واقعی، ناکارآمدی در برآورد زمان رسیدن (ETA) و عدم بهینگی در تخصیص ناوگان در ساعات اوج است.

پشتیبانی از تصمیم یا بینش عملیاتی: خروجی این تحلیل و پیش‌بینی‌ها مستقیماً از دو جنبه تصمیم‌گیری پشتیبانی می‌کند:

۱. مدیریت ناوگان و رانندگان: کمک به رانندگان و سیستم‌های اعزام برای اجتناب از ورود به دالان‌های با افت شدید سرعت در ساعات خاص و هدایت بهینه به سمت فرودگاه.

۲. برنامه‌ریزی مسافر و شفافیت هزینه: ارائه تخمین واقع‌بینانه از مدت‌زمان سفر و هزینه نهایی به مسافران جهت کاهش ریسک از دست دادن پرواز در ساعات پیک.

۲ شناخت منشأ داده (Data Origin) & Provenance

- منبع داده: داده‌های کمیسیون تاکسی و لیموزین شهر نیویورک (NYC TLC Trip Record Data).
- شیوه جمع‌آوری: داده‌ها به صورت خودکار توسط سیستم‌های پرداخت الکترونیکی و کنتورهای ثبت درون‌خودرویی تاکسی‌های زرد (Yellow Taxis) ثبت و در قالب فایل Parquet منتشر شده‌اند.
- بازه زمانی: ماه مارس ۲۰۲۳ (March 2023) شامل ۳۱ روز کامل.
- واحد مشاهده (**Unit of Observation**): هر سطر از داده، بیانگر «یک سفر تکمیل‌شده منفرد تاکسی» (A Single Completed Trip) است.
- ماهیت داده: داده کاملاً مشاهده‌ای (**Observational Data**) است و در بستر واقعی جریان روزمره شهری جمع‌آوری شده است؛ بنابراین متغیرهایی مانند آب‌وهوا یا رویدادهای پیش‌بینی‌نشده کنترل نشده‌اند.
- محدودیت‌های اصلی تولید داده: عدم ثبت موقعیت دقیق مکانی GPS در طول مسیر (صرفاً شناسه زون مبدأ و مقصد در دسترس است)، وجود خطاهای حسگر (نظیر مسافت صفر، مختصات یا مبالغ منفی) و ثبت نشدن تقاضاهای لغو شده یا پاسخ‌داده‌نشده.

۳ ممیزی ابعاد، ساختار و جریان داده‌ها (Data Audit) Schema & Architecture

۱.۳ ابعاد داده‌ها و ماهیت سوابق (Dataset Cardinality) & Dimensions

مجموعه‌داده مورد تحلیل در این پروژه از ادغام دو منبع اطلاعاتی مجزا در سیستم تاکسی‌رانی شهر نیویورک (NYC TLC) برای بازه زمانی مارس ۲۰۲۳ تشکیل شده است:

- داده تراکنش‌های سفر (Yellow Taxi Trips): این جدول دارای ۳،۴۰۳،۷۶۶ سطر و ۱۹ ستون است. هر سطر در این جدول، یک تراکنش قطعی انجام‌شده توسط ناوگان تاکسی‌های زرد را نشان می‌دهد و ماهیت داده از نوع سوابق با حجم بالا (High-volume Transactional Data) می‌باشد.

- داده مرجع مناطق (Zone Lookup): Metadata این جدول شامل ۲۶۵ سطر و ۴ ستون است که ساختار جغرافیایی و تقسیم‌بندی مناطق شهری نیویورک اعم از شناسه‌ها، نام مناطق و پهنه‌های خدماتی را شامل می‌شود.

۲.۳ طبقه‌بندی متغیرها و نقش تحلیلی آن‌ها (Feature Types) & Roles

متغیرهای ۱۹گانه جدول تراکنش‌ها بر اساس نقش تحلیلی و نوع داده در سه دسته کلیدی ممیزی می‌شوند:

۱. شناسه‌های رابطه‌ای و متغیرهای دسته‌ای (Foreign Keys & Categorical):

- `PULocationID` و `DOLocationID`: شناسه‌های فضایی از نوع `int32` هستند که پیوند جغرافیایی با جدول متادیتا را برقرار می‌کنند.
- `VendorID`، `RatecodeID`، و `payment_type`: شناسه‌های کدگذاری‌شده هستند که به ترتیب نوع ناوگان تأمین‌کننده، طرح تعرفه کرایه و روش تسویه مالی را مشخص می‌سازند.

۲. متغیرهای زمانی (Temporal Features):

- `tpep_pickup_datetime` و `tpep_dropoff_datetime`: نشانگرهای زمانی دقیق از نوع `datetime64[us]` که رخداد سوار و پیاده شدن مسافر را بر حسب سال، ماه، روز و ساعت/دقیقه/ثانیه ذخیره می‌کنند. متغیر مشتق‌شده `duration_min` از تفاضل این دو فیلد استخراج می‌شود.

۳. متغیرهای پیوسته و عددی (Continuous & Numerical):

- `trip_distance`: مسافت ثبت‌شده سفر بر حسب مایل از نوع `float64`.
- `passenger_count`: متغیر گسسته مربوط به تعداد مسافران داخل خودرو.
- متغیرهای مالی (`fare_amount`، `total_amount`، `tip_amount`، `tolls_amount`): مقادیر مالی و مالیاتی سفر که مبنای تحلیل درآمدی ناوگان قرار می‌گیرند.

۳.۳ تحلیل ارتباط رابطه‌ای و دیاگرام جریان داده (Relational Integration)

برای کاهش افزونگی و بهینه‌سازی حافظه، در جدول اصلی ۴.۳ میلیون سطری نام‌های متنی محله‌ها ذخیره نشده است. به جای آن، انتساب موقعیت مکانی از طریق یک ساختار رابطه‌ای با اتصال دوگانه (Dual Left Join) با جدول متادیتا صورت می‌پذیرد:

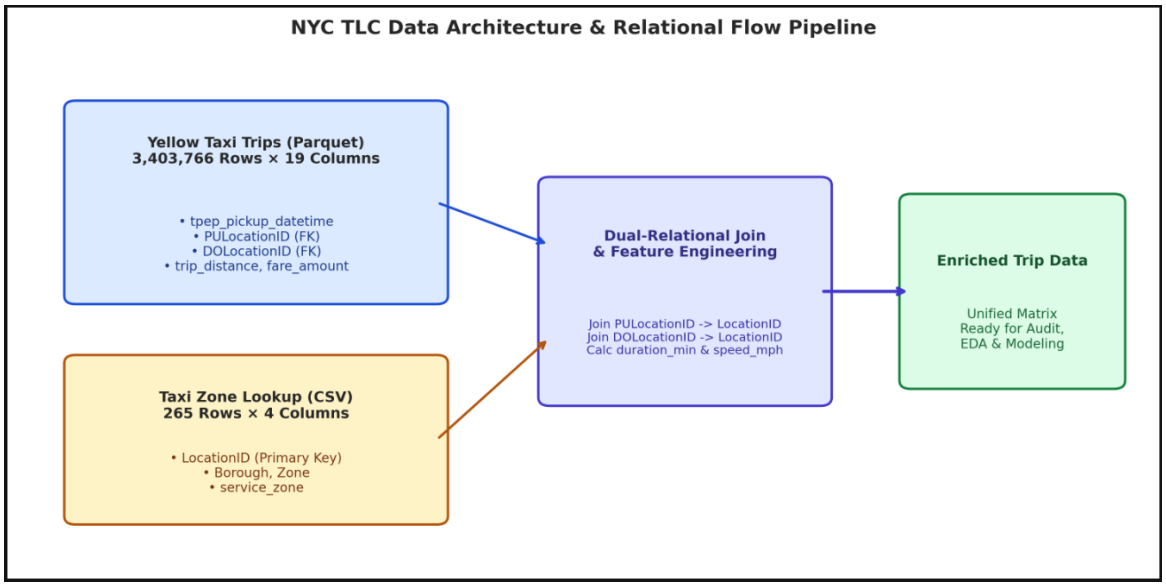
ساختار پیوند رابطه‌ای کلیدهای خارجی

$$\text{Trips.PULocationID} \xrightarrow{\text{Left Join}} \text{Zones.LocationID (Pickup Zone)}$$
$$\text{Trips.DOLocationID} \xrightarrow{\text{Left Join}} \text{Zones.LocationID (Dropoff Zone)}$$

این مکانیسم امکان دسترسی به متغیرهای فضایی نظیر منطقه جغرافیایی کلان (`Borough`) و نام ناحیه محلی (`Zone`) را بدون نیاز به تکثیر داده‌های متنی فراهم ساخته و ساختار نهایی را برای ممیزی کیفیت و مدلسازی آماده می‌سازد.

۴ ممیزی جامع کیفیت داده‌ها (Data Quality Audit)

در این مرحله، یک ممیزی سیستماتیک بر روی $3,403,766$ رکورد تراکنش خام انجام شد تا سلامت داده‌ها از منظر یکپارچگی، رکوردهای ناممکن، خطاهای لاگ و موارد پرت مورد سنجش قرار گیرد. جدول ۱ خلاصه کمی و تصمیمات عملیاتی قطعی برای گام پیش‌پردازش را نشان می‌دهد.



شکل ۱: نمودار معماری داده و پایپ‌لاین جریان اطلاعات پروژه TLC NYC

جدول ۱: ممیزی کیفیت داده‌ها و تصمیمات قطعی پیش‌پردازش (Data Preprocessing Decisions)

شاخص ممیزی	تعداد	درصد	تصمیم نهایی عملیاتی	دستورالعمل و توجیه فنی
سطرهای کاملاً تکراری (Duplicate Rows)	0	0.000%	تأیید سلامت (فاقد اقدام)	عدم وجود افزونگی؛ تضمین یکتایی سوابق تراکنش‌ها در پایگاه داده مرکزی.
مقادیر گم‌شده مسافر (passenger_count IS NULL)	$87,619$	2.574%	ایمپیوت میانه (1) + فلگ	پرهیز از حذف ۵٪.۲ داده سالم؛ انتساب میانه (1) و افزودن فیچر کمکی `is_missing`.
مدت‌زمان منفی یا صفر (duration ≤ 0)	$1,453$	0.043%	حذف کامل (**Hard Drop**)	خطای زمان‌سنجی ناوگان و نقض فیزیکی حرکت؛ حجم ناچیز ($< 0.05\%$) و عدم امکان تخمین.
مسافت ناممکن و صفر (trip_distance ≤ 0)	$48,528$	1.426%	فیلتر و حذف از مدل‌سازی	سفرهای لغوشده آنی؛ ممانعت از بروز خطای تقسیم بر صفر و تخریب محاسبات سرعت میانگین.

۱.۴ توجیه تحلیلی و مهندسی تصمیمات ممیزی

۱. رکوردهای تکراری (**Duplicate Records**): بررسی کل سطور با تمامی ۱۹ ستون نشان داد که هیچ رکورد تکراری مطلق در مجموعه‌داده وجود ندارد (Duplicates $= 0$). این امر بیانگر دقت بالای خط لوله انتقال داده‌های سنسوری و تراکنش‌های ناوگان تاکسی‌رانی است.

۲. داده‌های گم‌شده (**Missing Values**): تنها فیلد دارای داده گم‌شده ساخت‌یافته، `passenger_count` با ۸۷،۶۱۹ مورد (2.574%) است. از آنجا که حذف این حجم از سوابق موجب از دست رفتن داده‌های صحیح مسافت، زمان و کرایه می‌شود، استراتژی برخورد، جایگزینی با مقدار میانه (Median $= 1$) به همراه ایجاد یک ویژگی شاخص دودویی (`passenger_count_is_na`) خواهد بود تا مدل یادگیری ماشین در فازهای بعدی نسبت به داده‌های تخمینی آگاه باشد.

۳. ناسازگاری‌های فیزیکی و مقادیر ناممکن (**Impossible Values**):

- مدت‌زمان سفر (**duration** ≤ 0): تعداد ۱،۴۵۳ رکورد دارای مدت‌زمان مساوی یا کمتر از صفر هستند که ناشی از خطای همگام‌سازی ساعت خودروها یا لغو آنی سفر بلافاصله پس از ثبت سیستم است. این سوابق به دلیل نقض اصل فیزیکی جابه‌جایی و سهم ناچیز (0.043%)، به صورت کامل (Hard Drop) پالایش می‌شوند.
- مسافت صفر یا منفی (**trip_distance** ≤ 0): تعداد ۴۸،۵۲۸ سفر دارای مسافت صفر یا منفی هستند در حالی که مبالغ مالیاتی یا کرایه پایه برای آن‌ها ثبت شده است. این وضعیت گویای لغو سفر پس از روشن شدن تاکسی‌متر بوده و نگه‌داشتن آن‌ها متغیرهایی نظیر سرعت میانگین ($v = d/t$) را با خطای محاسباتی مواجه می‌کند؛ لذا از داده‌های آموزش مدل‌های حمل‌ونقل کنار گذاشته می‌شوند.

۵ تحلیل اکتشافی تک‌متغیره (Univariate Exploratory Data Analysis)

در این بخش، ویژگی‌های آماری بنیادین شامل معیارهای گرایش به مرکز (میانگین و میانه)، شاخص‌های پراکندگی (انحراف معیار و دامنه میان‌چارکی) و شکل توزیع (چولگی و کشیدگی) برای چهار متغیر کلیدی ترافیکی و مالی مورد ارزیابی قرار گرفته است.

۱.۵ آماره‌های توصیفی و شکل توزیع متغیرها

جدول ۲ شاخص‌های تجمیعی استخراج‌شده از ۴.۳ میلیون سفر را نمایش می‌دهد. به دلیل چولگی شدید به راست، میانه معیار به مراتب پایدارتر و قابل اتکاتری نسبت به میانگین برای تبیین مرکز توزیع رفتار سفرهاست.

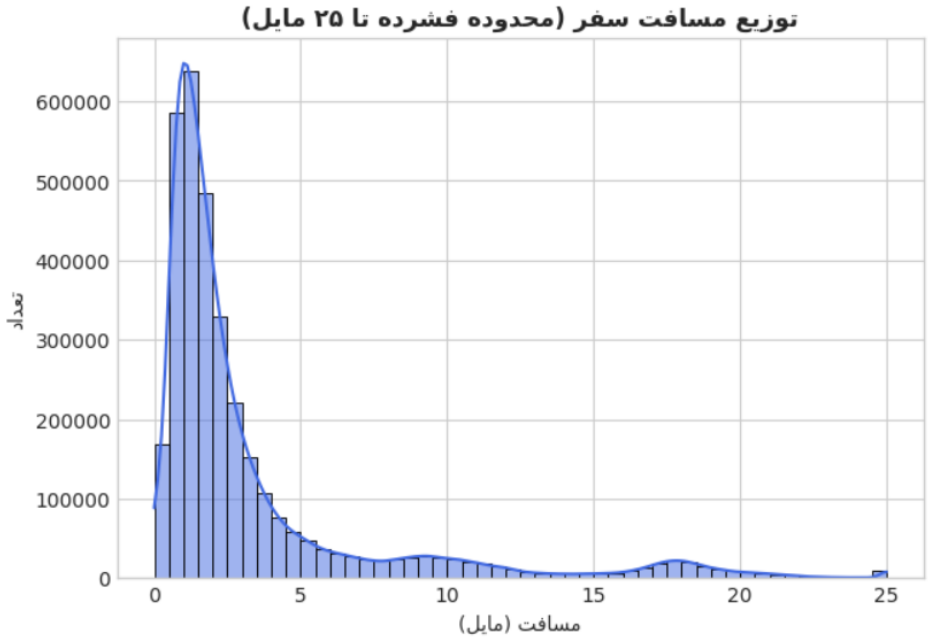
جدول ۲: خلاصه آماره‌های توصیفی، پراکندگی و چولگی متغیرهای منتخب

متغیر	میانگین	انحراف معیار	چارک اول (Q_1)	میانه (Q_2)	چارک سوم (Q_3)	ضریب چولگی (**Skew**)
مسافت سفر (trip_distance)	3.90	3.38	1.05	2.33	3.38	+191.69
مدت سفر (duration_min)	16.88	19.65	7.40	12.25	19.65	+43.79
مبلغ پرداختی (total_amount)	27.80	29.76	14.06	20.60	29.76	+22.87
تقاضای ساعتی (hourly_demand)	7.55	77.77	0.00	1.00	6.00	+2.53

۲.۵ تفسیر بصری و الگوهای رفتاری ناوگان

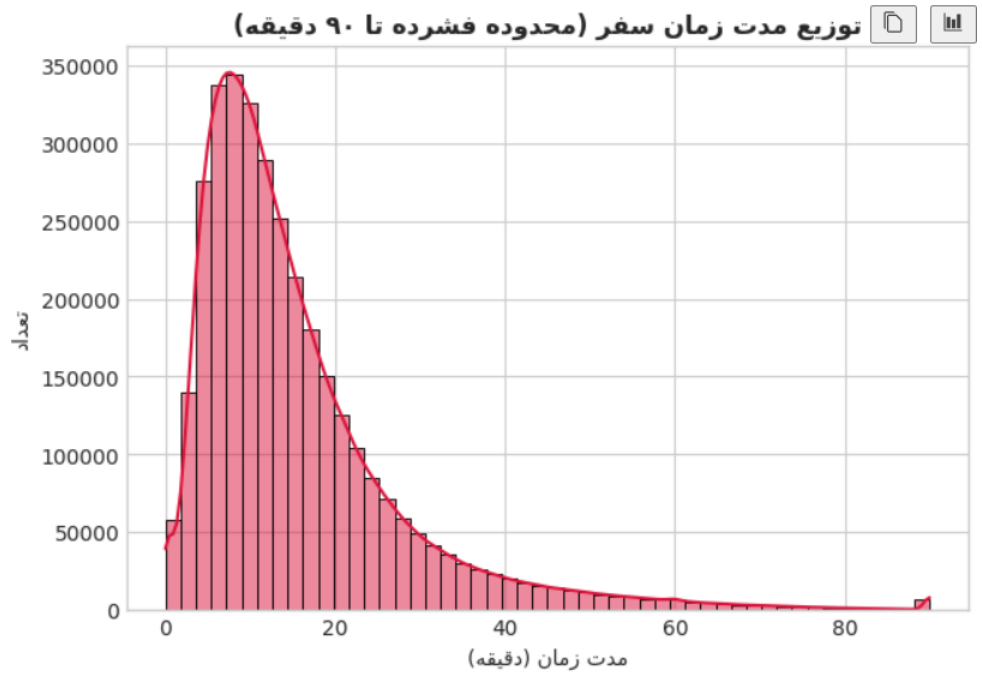
نمودارهای به دست آمده الگوی رفتاری زیر را آشکار می‌سازند:

۱. توزیع مسافت سفر (هیستوگرام و **KDE**): توزیع مسافت دارای یک قله بسیار تیز در بازه 1 تا 2.5 مایل است که نشان می‌دهد بیشینه مطلق جابه‌جایی‌های تاکسی زرد نیویورک سفرهای بسیار کوتاه درون‌شهری در منهتن هستند. همچنین وجود قله‌های کوچک ثانویه در فواصل حدود ۱۰ و ۱۷ مایلی، نمایانگر سفرهای پرتکرار بین‌شهری به سمت فرودگاه‌های LGA و JFK است. ضریب چولگی مثبت بالا ($+191.69$) اثر رکوردهای پرت با مسافت‌های نامتعارف را نشان می‌دهد.



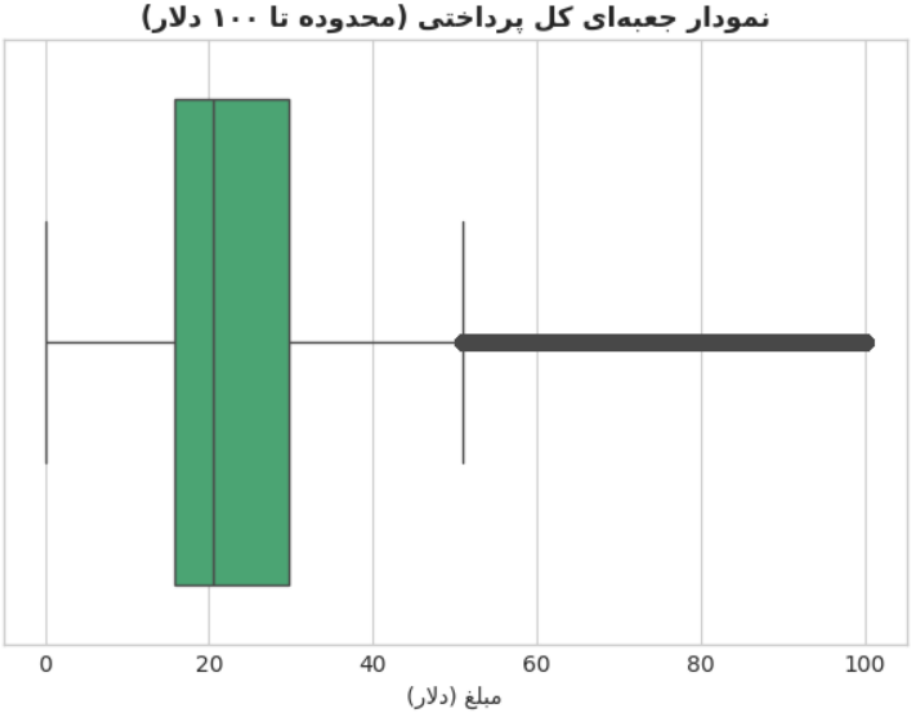
شکل ۲: هیستوگرام و نمودار چگالی مسافت سفر (تا ۲۵ مایل)

۲. توزیع مدت‌زمان سفر: مدت سفرها در محدوده 5 تا 15 دقیقه متمرکز است (با میانه 12.25 دقیقه). دنباله کشیده توزیع تا زمان‌های فراتر از ۶۰ دقیقه، بازتاب‌دهنده ترافیک‌های سنگین ساعات اوج کاری (Rush Hours) و سفرهای طولانی برون‌شهری است.



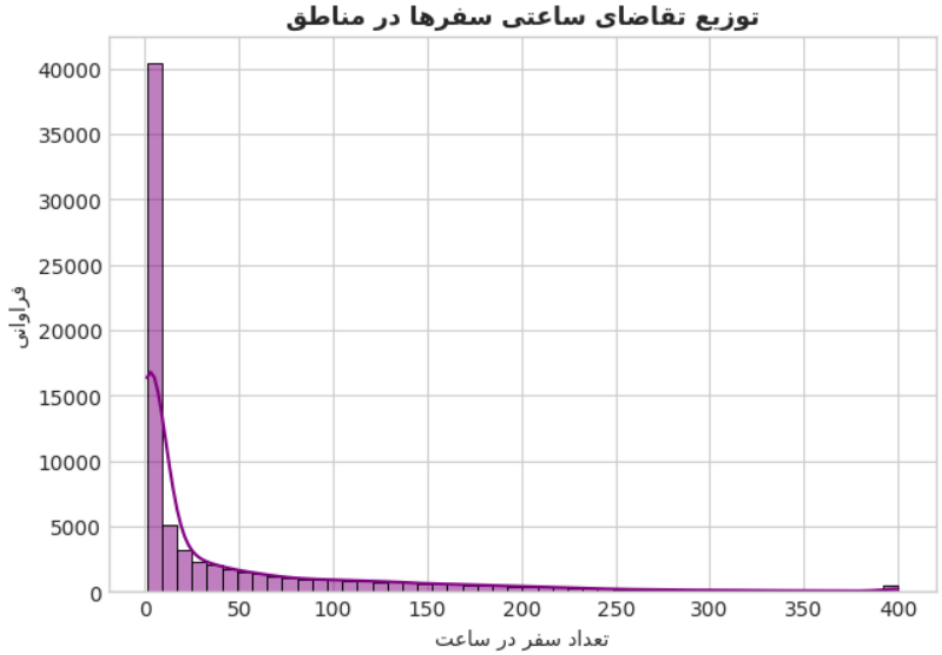
شکل ۳: هیستوگرام و نمودار توزیع مدت زمان سفر

۳. تحلیل جعبه‌ای کل پرداختی (**total_amount**): نمودار جعبه‌ای نشان می‌دهد ۵۰٪ مرکزی پرداخت‌ها (IQR) در بازه ۱۴ تا ۳۰ دلار قرار دارند. تمرکز متراکم داده‌های پرت (Outliers) در بالای ۵۰ دلار، مربوط به تعرفه‌های مقطوع فرودگاهی (70 دلار) و سفرهای با مسافت بالا همراه با عوارض بزرگراهی است.



شکل ۴: نمودار جعبه ای کل پرداختی

۴. عدم تقارن شدید در تقاضای مکانی-زمانی (**Spatial Sparsity**): توزیع تقاضای ساعتی نشان می‌دهد که برای اکثریت قریب به اتفاق مناطق و ساعات شبانه‌روز، تعداد سفر نزدیک به صفر یا بسیار کم است (میانه برابر با ۱ سفر)، در حالی که تعداد اندکی از زون‌های مرکزی (مانند منهتن مرکزی و فرودگاه‌ها) با ثبت صدها سفر در ساعت، حجم عمده ناوگان را به خود جذب می‌کنند. این چولگی مکانی نیازمند مقیاس‌بندی لگاریتمی در فاز مدل‌سازی است.



شکل ۵: هیستوگرام و نمودار توزیع تقاضای ساعتی سفر ها در مناطق

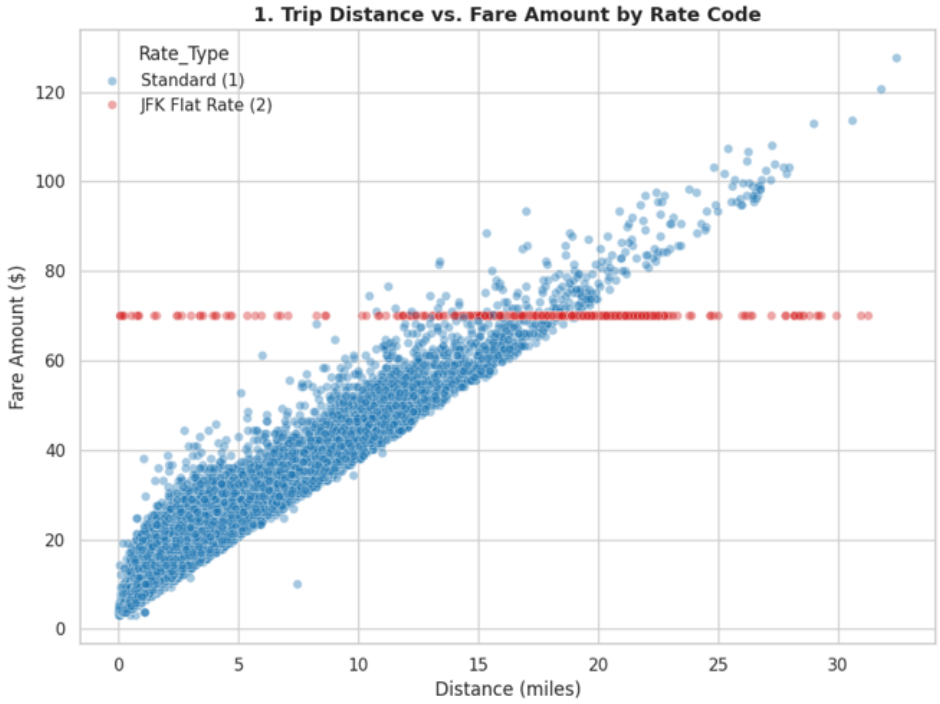
۶ تحلیل اکتشافی چندمتغیره Analysis) Data Exploratory (Multivariate

در این بخش، الگوهای تعاملی و همبستگی ساختاری میان متغیرهای عملیاتی، مالی و زمانی ناوگان با تفکیک بر اساس متغیرهای رده‌ای بررسی شده است. شکل‌های ؟؟ و ؟؟ چهار بعد تحلیلی کلیدی را به تصویر می‌کشند.

۱.۶ تحلیل رفتار تعرفه‌ای و اثر رژیم قیمت‌گذاری (**Rate Code Interaction**)

نمودار پراکندگی مسافت در برابر کرایه پایه (Fare Amount)، یک پدیده دوشاخه‌ای (Bifurcation) قطعی در ساختار کرایه‌ها را آشکار می‌سازد:

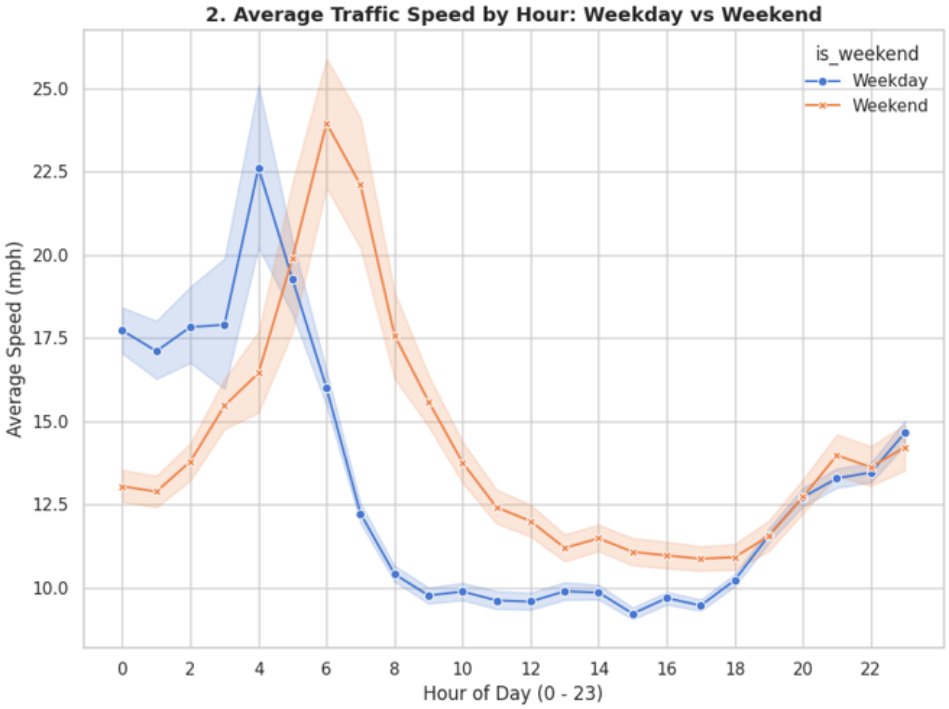
- نرخ استاندارد شهری (**Standard Rate - Code 1**): رابطه خطی بسیار قوی و مستقیمی با شیب مثبت میان مسافت و کرایه حاکم است ($r = 0.97$). پراکندگی عمودی در مسافت‌های ثابت بازتاب‌دهنده اثر توقف در ترافیک سنگین (محاسبه کرایه بر مبنای زمان سپری‌شده به ازای هر دقیقه توقف) است.
- نرخ مقطوع فرودگاهی (**JFK Flat Rate - Code 2**): یک خط کاملاً افقی و صلب در کرایه پایه 70 دلار ($y = 70$) تشکیل شده است. در این رژیم قیمتی، مسافت سفر (که نوعاً بین ۸ تا ۲۵ مایل متغیر است) هیچ تأثیری بر کرایه پایه ندارد. تفکیک این زیرگروه در مدل‌سازی تقاضا و رگرسیون کرایه از ایجاد بایاس محاسباتی جلوگیری می‌کند.



۲.۶ دینامیک سرعت ترافیک و اثر چرخه هفتگی (**Speed Dynamics by Day Type**)

محاسبه سرعت متوسط ناوگان از رابطه $v = \frac{\text{trip_distance}}{\text{duration_min}/60}$ و تحلیل آن در طول ۲۴ ساعت شبانه‌روز (همراه با بازه اطمینان ۹۵٪) دو رفتار کاملاً متمایز را نشان می‌دهد:

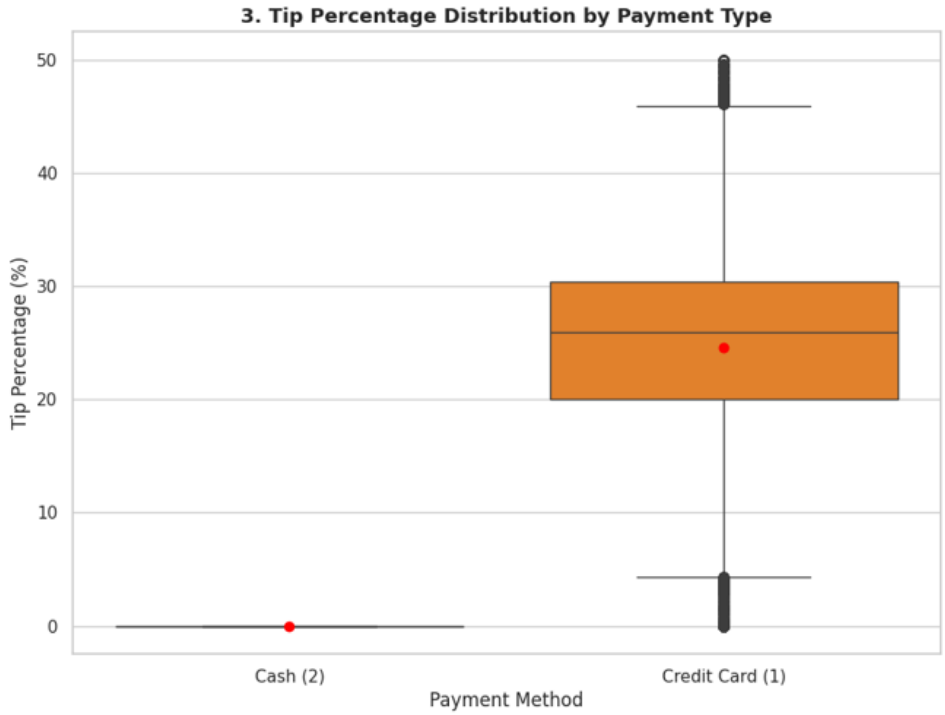
- روزهای کاری (**Weekday**): سرعت ناوگان از ساعت ۵ صبح دچار افت بسیار شدیدی شده و در طول ساعات اداری (ساعت ۸ الی ۱۸) در کف حدود 9.5 الی 10 مایل بر ساعت منجمد می‌شود که گویای ترافیک متراکم هسته شهری است. بیشینه سرعت در ساعت ۴ صبح (22.5 mph) رخ می‌دهد.
- روزهای آخر هفته (**Weekend**): قله سرعت با ۲ ساعت تأخیر در ساعت ۶ صبح به حدود 24 mph می‌رسد. سرعت در طول روزهای آخر هفته همواره 1.5 تا 2.5 مایل بر ساعت بالاتر از روزهای کاری است که تفاوت در الگوی سفرهای اداری و تفریحی را اثبات می‌کند.



۳.۶ بایاس ثبتی انعام بر اساس شیوه پرداخت (**Tipping Behavior by Payment**)

نمودار جعبه‌ای درصد انعام پرداختی (Tip Percentage) تفاوت زیرساختی عمیقی را نشان می‌دهد:

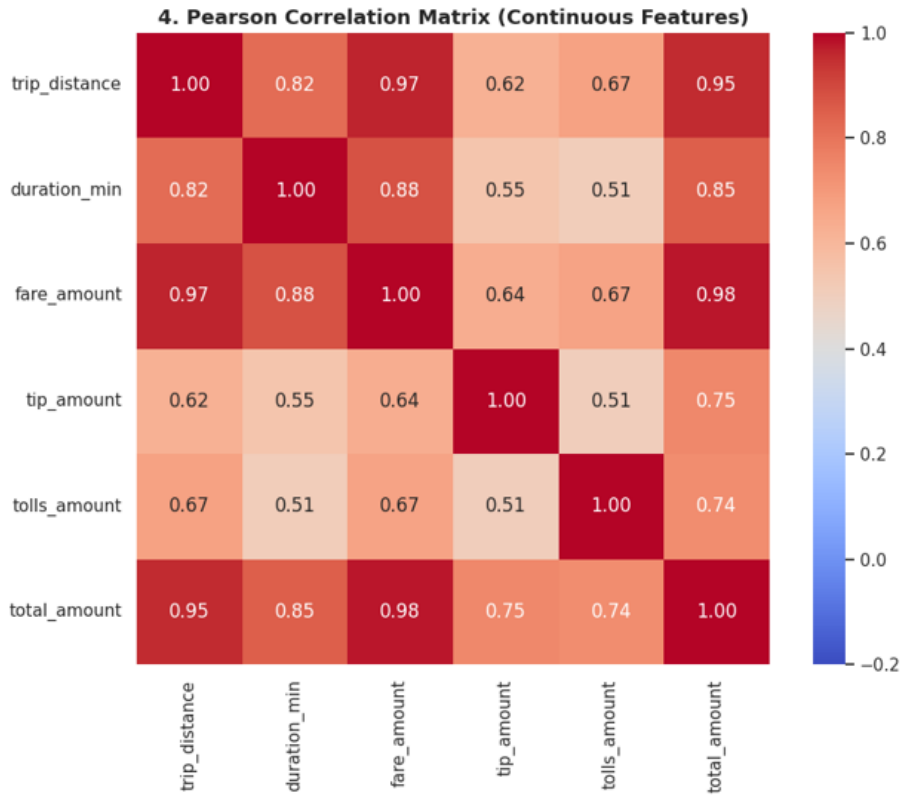
- پرداخت‌های نقدی (**Cash - 2**): در ۱۰۰٪ موارد مقدار انعام ثبت‌شده در سیستم برابر با صفر است (0%). این مقدار ناشی از عدم تمایل رانندگان به پرداخت انعام نیست، بلکه ناشی از محدودیت ذاتی سیستم لاگ تاکسی‌متر است که انعام نقدی پرداخت‌شده توسط مسافر را ثبت نمی‌کند.
- پرداخت‌های اعتباری (**Credit Card - 1**): میانه انعام روی خط پیشنهادی پیش‌فرض دستگاه کارت‌خوان (26%) تثبیت شده و بیش از ۷۵٪ تراکنش‌ها در بازه 20% تا 30% قرار دارند. بنابراین، تحلیل رفتار سخاوتمندی مسافران صرفاً باید به تراکنش‌های اعتباری محدود گردد تا از خطای عدم مشاهده (Observational Bias) پیشگیری شود.



۴.۶ ماتریس همبستگی پیرسون و هم‌خطی متغیرها (**Multicollinearity**)

ماتریس همبستگی پیرسون بین متغیرهای پیوسته نشان می‌دهد:

- همبستگی نزدیک به ۱ بین کرایه پایه (fare_amount) و مبلغ کل (total_amount) ($r = 0.98$) و مسافت سفر ($r = 0.97$).
- همبستگی مسافت با زمان سفر برابر با $r = 0.82$ است که هر دو مؤلفه اثرگذار اصلی بر کرایه نهایی هستند.
- وجود این سطح بالا از همبستگی هشدار می‌دهد که در مدل‌های رگرسیونی خطی، متغیرهای trip_distance و duration_min و fare_amount به صورت همزمان نباید به عنوان متغیرهای مستقل وارد شوند تا از مشکل هم‌خطی چندگانه (Multicollinearity) اجتناب شود.



۷ تحلیل نشت اطلاعات (Data Leakage)

نشت اطلاعات یعنی اطلاعاتی که در دنیای واقعی در لحظه سوار شدن مسافر وجود ندارند، به مدل آموزش داده شوند و باعث ایجاد خطای کاذب و توهم دقت شوند:

- ویژگی‌های آینده (پس از پایان سفر): متغیرهایی مانند زمان رسیدن به مقصد (`dropoff_datetime`)، مبلغ انعام (`tip_amount`)، عوارض (`tolls_amount`) و کل پرداختی (`total_amount`) تنها پس از پایان سفر ثبت می‌شوند. اگر این متغیرها به عنوان ورودی برای تخمین کرایه پایه استفاده شوند، مدل عملاً «پاسخ را از قبل می‌داند». بنابراین، فقط از متغیرهای لحظه سوار شدن (زمان، روز و مکان مبدأ) استفاده می‌شود.
- واحد صحیح تقسیم داده‌ها (Splitting Unit): تقسیم تصادفی (Random Shuffle) برای داده‌های زمانی اشتباه است؛ زیرا الگوهای آینده به گذشته نفوذ می‌کنند. واحد صحیح تقسیم، پنجره زمانی است. بر این اساس، داده‌های روزهای ۱ تا ۲۱ مارس به عنوان مجموعه آموزش (Train) و داده‌های روزهای ۲۲ تا ۳۱ مارس به عنوان مجموعه آزمون (Test) در نظر گرفته شدند.

۸ تعریف خط مبنای ساده (**Baseline**) و سنجش عملکرد

یک مدل یادگیری ماشین و تحلیل داده زمانی ارزش واقعی دارد که عملکرد آن از یک حدس اولیه و شهودی بسیار ساده و قابل‌فهم فراتر رود؛ در غیر این صورت، پیچیدگی مدل هیچ ارزش افزوده‌ای به همراه نخواهد داشت.

- تعریف خط مبنای ساده (**Naive Mean Baseline**): ساده‌ترین تصمیم ممکن برای پیش‌بینی کرایه خام سفرهای دوره آزمون (روزهای پایانی مارس)، استفاده از میانگین حسابی کرایه‌های آموزش‌دیده در سه هفته اول است:

$$\hat{y} = \bar{y}_{\text{train}}$$

در این رویکرد، مدل بدون توجه به هیچ‌یک از ویژگی‌های سفر (مسافت، زمان، مبدأ، مقصد یا شرایط ترافیکی)، برای هر سفر جدید مقدار ثابت میانگین را برآورد می‌کند.

۱.۸ نتایج ارزیابی خط مبنا روی داده‌های آزمون

با تقسیم زمانی داده‌های خام بر مبنای پنجره زمانی (سه هفته نخست برای آموزش و ادامه ماه برای آزمون)، عملکرد خط مبنا به شرح زیر استخراج گردید:

جدول ۳: عملکرد خط مبنای ساده (Naive Baseline) روی مجموعه آزمون

شاخص / معیار ارزیابی	مقدار
تعداد داده‌های آموزش (Train Records)	۲،۳۱۶،۱۵۴
تعداد داده‌های آزمون (Test Records)	۱،۰۸۷،۶۱۲
میانگین کرایه خام آموزش (Baseline Prediction)	۱۸٫۸۱ دلار
خطای میانگین قدرمطلق (MAE) روی آزمون	۱۱٫۸۳ دلار
ریشه میانگین مربعات خطا (RMSE) روی آزمون	۱۸٫۴۸ دلار

تحلیل و ارزش افزوده در فازهای بعدی:

- خطای میانگین قدرمطلق (MAE) برابر با ۱۱٫۸۳ دلار نشان می‌دهد که این حدس ناآگاهانه به طور میانگین نزدیک به ۱۲ دلار انحراف از کرایه واقعی دارد.
- خطای ریشه میانگین مربعات (RMSE) برابر با ۱۸٫۴۸ دلار نیز حساسیت شدید به سفرهای طولانی‌تر یا مبالغ نامتعارف را نشان می‌دهد.
- این دو مقدار به عنوان سنگ‌محک پایه‌ای (**Benchmark**) در کل پروژه ثبت می‌شوند؛ مدل‌های پیشرفته‌تر (شامل مهندسی ویژگی‌های مکانی و زمانی دالان منهتن تا JFK) تنها در صورتی ارزش استقرار و پیچیدگی را خواهند داشت که بتوانند خطاها را نسبت به این مقادیر پایه به طور معناداری کاهش دهند.

۹ طرح سه سؤال اولیه و انتخاب سؤال نهایی

به منظور هدایت پژوهش، ابتدا سه سؤال اولیه طراحی گردید:

۱. سؤال ۱ (پیش‌بینی مسافت و رفتار پرداخت): آیا مدل‌های رگرسیونی می‌توانند سهم انعام (Tip) را بر اساس نوع پرداخت و مسافت تخمین بزنند؟

۲. سؤال ۲ (شناسایی ترافیک و سرعت کریدورها): چگونه نوسانات سرعت سیر تاکسی‌ها در ساعات اوج و روزهای هفته، گلوگاه‌های افت سرعت بین منهتن و فرودگاه JFK را پدید می‌آورد؟

۳. سؤال ۳ (پیش‌بینی توأم زمان و هزینه): آیا می‌توان با ترکیب الگوهای زمانی و مکانی، مدت‌زمان سفر (Trip Duration) و کرایه نهایی را برای سفرهای بین منهتن و JFK پیش‌بینی کرد؟

سؤال اصلی نهایی با استدلال روشن: سؤال سوم (با تأکید بر تحلیل سرعت) به عنوان سؤال محوری نهایی برگزیده شد:

> «آیا می‌توان با ترکیب الگوهای زمانی (ساعت روز و روزهای کاری در برابر آخر هفته) و مشخصات مکانی، مدت‌زمان سفر (Trip Duration) و کرایه نهایی (Total Amount) را برای سفرهای بین منهتن (Manhattan) و فرودگاه JFK پیش‌بینی کرد و گلوگاه‌های افت سرعت شبکه (ترافیک شدید) را شناسایی نمود؟»

استدلال انتخاب: سفرهای فرودگاهی به دلیل کرایه‌های خاص، حساسیت شدید به زمان و تأثیرپذیری بالا از گلوگاه‌های بزرگراهی، بالاترین ارزش اقتصادی و عملیاتی را برای بهینه‌سازی دارند و نتایج آن صرفاً یک پیش‌بینی آماری نبوده، بلکه راهنمای عملیاتی ناوگان است.

۱۰ ممیزی و تحلیل زمانی سفرها (**Temporal Audit and Patterns**)

در این بخش، صحت زمانی داده‌ها، توزیع چرخه‌ای سفرها در مقیاس‌های روزانه، هفتگی و ساعتی، و همچنین کشف دوره‌های اوج تقاضا (Peak) و افت (Off-Peak) مورد تحلیل و ممیزی قرار گرفته است.

۱.۰.۱۰ ممیزی سلامت و محدوده زمانی رکوردهای ثبت‌شده

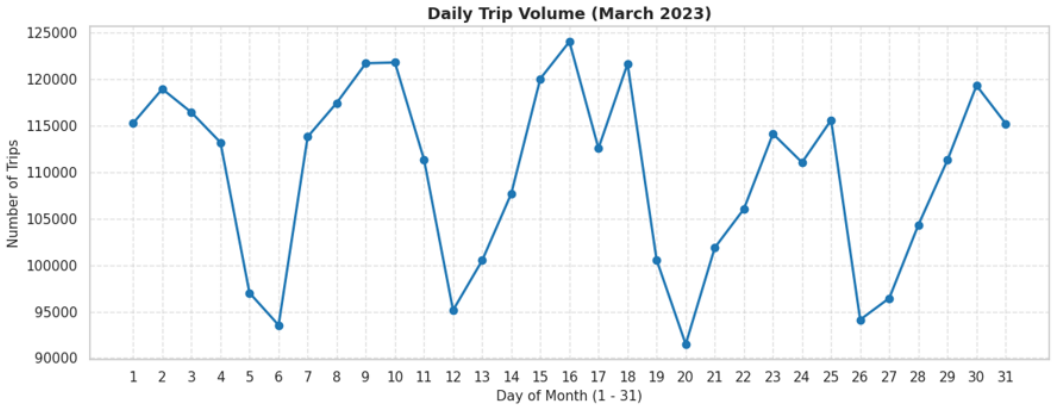
مجموع داده‌های خام بارگذاری‌شده شامل 3,403,766 رکورد است. با بررسی برچسب‌های زمانی دریافت مسافر (tpep_pickup_datetime)، نتایج زیر حاصل شد:

- رکوردهای معتبر درون بازه: تعداد 3,403,577 رکورد (معادل 99.99%) دقیقاً در بازه رسمی ماه مارس ۲۰۲۳ (2023-03-01 الی 2023-03-31) ثبت شده‌اند.
- ناهنجاری‌های تاریخی (**Date Outliers**): تعداد ۱۸۹ رکورد (معادل 0.0056%) خارج از بازه زمانی ماه هدف قرار دارند؛ به‌طوری‌که قدیمی‌ترین زمان ثبت‌شده مربوط به 2001-01-01 00:06:49 و جدیدترین آن مربوط به 2023-05-04 20:17:42 است. این موارد به خطای ساعت دستگاه‌های MDT تاکسی‌ها مربوط بوده و در مرحله پالایش حذف می‌شوند.

۲.۰.۱۰ تحلیل سری زمانی حجم روزانه در ماه مارس ۲۰۲۳

بررسی روند تغییرات روزانه تعداد سفرها در شکل ۶ رفتار تناوبی قدرتمند ناشی از روزهای کاری و تعطیلات پایان هفته را نشان می‌دهد:

- الگوی افت و خیز دوره‌ای: در تقویم مارس ۲۰۲۳، روزهای ۶، ۱۳، ۲۰ و ۲۷ مصادف با روزهای دوشنبه هستند که پس از تعطیلات یکشنبه رخ داده و نقاط حضیض هفتگی (کمترین حجم تقاضا در حدود ۹۰ تا ۹۵ هزار سفر) را تشکیل می‌دهند.
- روزهای پرتقاضا: در اواسط تا پایان هفته‌های کاری (به‌ویژه روزهای پنج‌شنبه و جمعه مانند ۱۶ مارس با بیش از ۱۲۴ هزار سفر) بیشترین حجم تقاضا در شبکه مشاهده می‌شود.

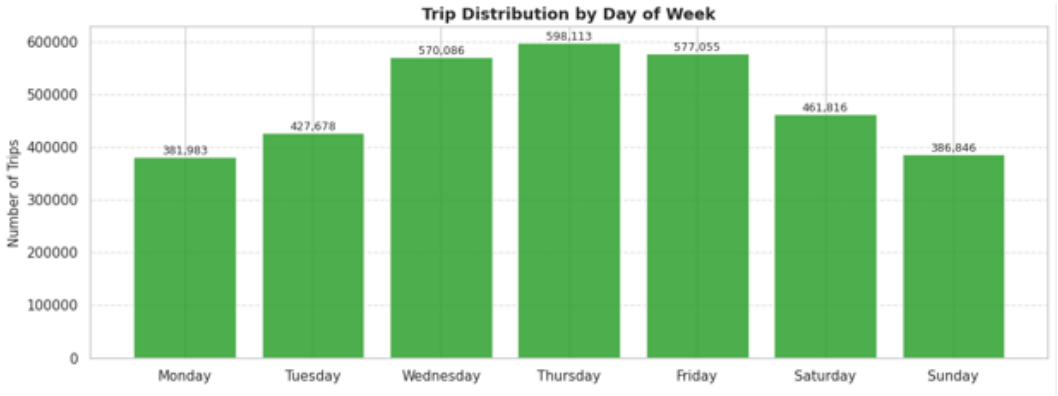


شکل ۶: روند حجم روزانه سفرهای تاکسی در طول ماه مارس ۲۰۲۳

۳.۰.۱۰ توزیع روزهای هفته (**Day of Week**)

نمودار ستونی توزیع سفرها بر اساس روزهای هفته در شکل ۷ تغییر تقاضای درون‌شهری را به‌روشنی بازتاب می‌دهد:

- روزهای اوج تقاضا (**Peak Days**): روزهای کاری پایانی هفته یعنی پنج‌شنبه (**Thursday**) با ۵۹۸،۱۱۳ سفر، جمعه (**Friday**) با ۵۷۷،۰۵۵ سفر و چهارشنبه (**Wednesday**) با ۵۷۰،۰۸۶ سفر شلوغ‌ترین روزها هستند که ناشی از ترکیب سفرهای اداری-تجاری و تفریحات شبانه در منهتن است.
- روزهای افت تقاضا (**Off-Peak Days**): روزهای دوشنبه (۳۸۱،۹۸۳ سفر) و یکشنبه (۳۸۶،۸۴۶ سفر) به دلیل تعطیلی ادارات و کاهش ترددهای درون‌شهری کم‌ترافیک‌ترین روزها به شمار می‌روند.



شکل ۷: توزیع تجمعی سفرهای ماه مارس بر حسب روزهای هفته

۴.۰.۱۰ پروفایل ساعتی تقاضا (**24-Hour Profile**)

مطابق با هیستوگرام ۲۴ ساعته در شکل ۸، دینامیک زمانی ناوگان تاکسیرانی را می‌توان به دو بخش مجزا تفکیک کرد:

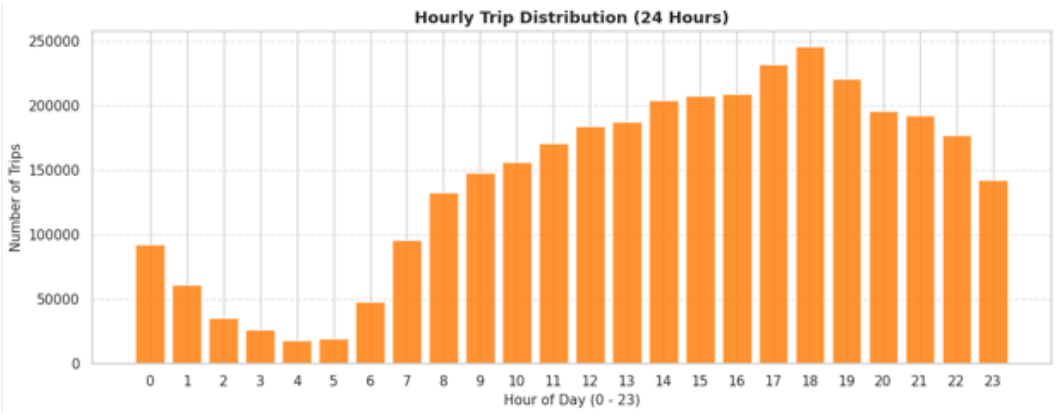
۱. ساعات اوج تقاضا (**Peak Hours**):

- ساعت ۱۸:۰۰ تا ۱۹:۰۰ با ۲۴۵،۶۰۴ سفر (بیشینه مطلق روزانه).
- ساعت ۱۷:۰۰ تا ۱۸:۰۰ با ۲۳۱،۸۳۴ سفر.
- ساعت ۱۹:۰۰ تا ۲۰:۰۰ با ۲۲۰،۶۹۸ سفر.

این پیک بعدازظهر بازتاب خروج کارمندان از مراکز تجاری منهتن و شروع برنامه‌های عصرگاهی است.

۲. ساعات افت تقاضا (**Off-Peak Hours**):

- ساعت ۰۴:۰۰ تا ۰۵:۰۰ صبح با ۱۸،۱۱۶ سفر (کمینه تقاضا در کل شبانه‌روز).
- ساعت ۰۵:۰۰ تا ۰۶:۰۰ صبح با ۱۹،۴۴۴ سفر.
- ساعت ۰۳:۰۰ تا ۰۴:۰۰ صبح با ۲۶،۸۷۷ سفر.



شکل ۸: توزیع ساعتی سفرهای تاکسیرانی در شبانه‌روز (ساعات ۰ تا ۲۳)

نتیجه‌گیری ممیزی زمانی برای مدل‌سازی: وجود periodicity قوی در دو بعد روز هفته و ساعت نشان می‌دهد که متغیرهای استخراجی زمانی مانند Hour of Day، Day of Week و برچسب‌های دوگانه Is_Rush_Hour و Is_Weekend از حیاتی‌ترین ویژگی‌ها (Features) برای آموزش مدل‌های پیش‌بینی تقاضا و تخمین زمان سفر خواهند بود.

۱۱ ممیزی سازگاری متغیرهای سفر (Trip Consistency Audit)

در این بخش، صحت فیزیکی و منطقی روابط متقابل میان متغیرهای کلیدی سفر شامل مدت زمان سفر (Duration)، مسافت (Trip Distance)، کرایه پایه (Fare Amount) و سرعت محاسبه‌شده (Implied Speed) مورد سنجش و ارزیابی قرار گرفت. هدف از این ممیزی، شناسایی رکوردهای مخدوش، ناهنجاری‌های فیزیکی و داده‌های ناشی از خطای ثبتی است.

۱.۰.۱۱ شناسایی رکوردهای ناسازگار و غیرممکن

از مجموع ۳،۴۰۳،۷۶۶ رکورد موجود در مجموعه‌داده، موارد ناهنجار زیر استخراج و دسته‌بندی گردیدند:

۱. ناهنجاری‌های زمانی:

- تعداد ۳۵۷ رکورد دارای زمان معکوس (Pickup پس از Dropoff) بودند که نشان‌دهنده خطای شدید در همگام‌سازی ساعت تاکسی‌متر است.
- تعداد ۱،۰۹۶ سفر با مدت زمان دقیقاً صفر ثانیه ثبت شده‌اند.
- تعداد ۲۱ رکورد دارای مدت زمان غیرواقعی و بیش از ۲۴ ساعت بودند.

۲. مسافت مثبت با زمان صفر یا منفی: تعداد ۴۴۹ رکورد (0.013%) دارای مسافت جابه‌جایی مثبت بوده‌اند در حالی که مدت زمان ثبت‌شده برای آن‌ها صفر یا منفی بوده است که از نظر قوانین فیزیکی غیرممکن است.

۳. سرعت‌های غیرواقعی و غیرممکن فیزیکی (> 80mph): با محاسبه سرعت متناظر هر سفر از رابطه $v = \frac{\text{Distance}}{\text{Duration}}$، تعداد ۲،۲۳۲ رکورد ($0.066\%$) سرعتی فراتر از ۸۰ مایل بر ساعت (حد مجاز شهری و بزرگراهی نیویورک) داشته‌اند که نشان‌دهنده جهش موقعیت مکانی یا خطای سنسور ثبت مسافت است.

۴. ناهنجاری‌های مالی و کرایه:

- مسافت صفر با کرایه بالا ($> \$5$): تعداد ۳۱،۴۸۷ رکورد ($0.925\%$) بدون ثبت مسافت، کرایه‌ای فراتر از نرخ ورودی پایه داشته‌اند (مربوط به هزینه‌های کنسلی یا خطای راننده).
- مسافت طولانی با کرایه صفر یا منفی: تعداد ۹،۵۸۰ رکورد (0.281%) با وجود پیمایش بیش از ۲ مایل، کرایه‌ای معادل صفر یا منفی دریافت کرده‌اند.
- کرایه‌های منفی (**Negative Fares**): مجموعاً ۲۹،۶۷۷ رکورد (0.872%) دارای کرایه منفی بودند که عمدتاً حاصل تراکنش‌های اصلاحی یا استرداد وجه (Refund) است.

جدول ۴: خلاصه رکوردهای ناسازگار و خطاهای فیزیکی شناسایی‌شده در کل دیتاست

شاخص ممیزی	تعداد رکورد	درصد	تفسیر منطقی
زمان پیاده‌شدن قبل از سوارشدن	۳۵۷	0.010%	خطای ثبت یا تداخل زمانی سنسور
مدت زمان صفر یا منفی با مسافت مثبت	۴۴۹	0.013%	جابه‌جایی آنی (غیرممکن فیزیکی)
سرعت ناممکن (> 80mph)	۲،۲۳۲	0.066%	خطای کیلومترشمار یا ناهنجاری مکانی
مسافت طولانی (> 2mi) با کرایه منفی یا صفر	۹،۵۸۰	0.281%	عدم ثبت تراکنش، تسویه‌نشده یا تخفیف
کرایه منفی (Negative Fares)	۲۹،۶۷۷	0.872%	استرداد وجه و تراکنش‌های برگشتی
مسافت صفر با کرایه بالا ($> \$5$)	۳۱،۴۸۷	0.925%	جریمه کنسلی، انتظار یا خطای ثبتی

۲.۰.۱۱ تحلیل روابط متقابل و ماتریس همبستگی (داده‌های معتبر)

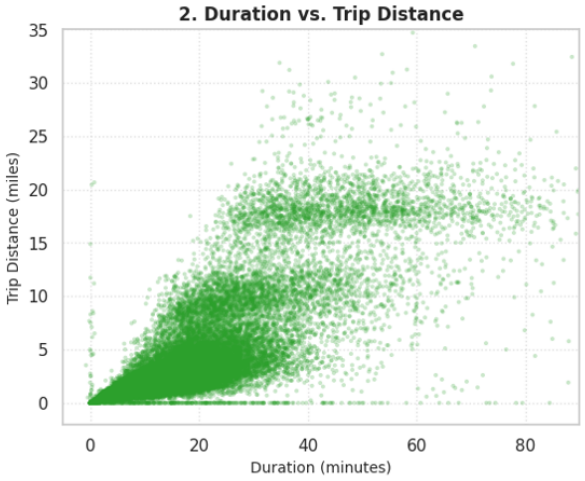
پس از پالایش موقت داده‌های غیرممکن، سازگاری منطقی میان متغیرها در زیرمجموعه معتبر محاسبه گردید. ماتریس همبستگی پیرسون حاکی از نتایج زیر است:

- رابطه مسافت و کرایه ($r = 0.953$): همبستگی بسیار بالا و مثبت مستقیم، تأییدکننده پیروی دقیق فرمول تعرفه رسمی از مسافت طی‌شده است.

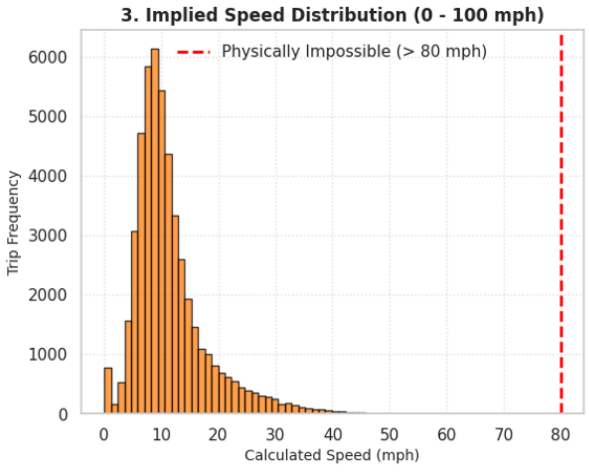
- رابطه مسافت و مدت زمان ($r = 0.815$): نشان‌دهنده رابطه قوی میان زمان و مسافت است؛ هرچند ترافیک متراکم شهری باعث کاهش نسبی این همبستگی نسبت به رابطه مسافت-کرایه شده است.
- همبستگی سرعت با سایر متغیرها ($r \approx 0.00 - 0.05$): سرعت به‌دلیل وابستگی بالا به ساعات شبانه‌روز و شرایط ترافیکی محلی، همبستگی خطی ناچیزی با مقدار کرایه یا مسافت مستقیم دارد.



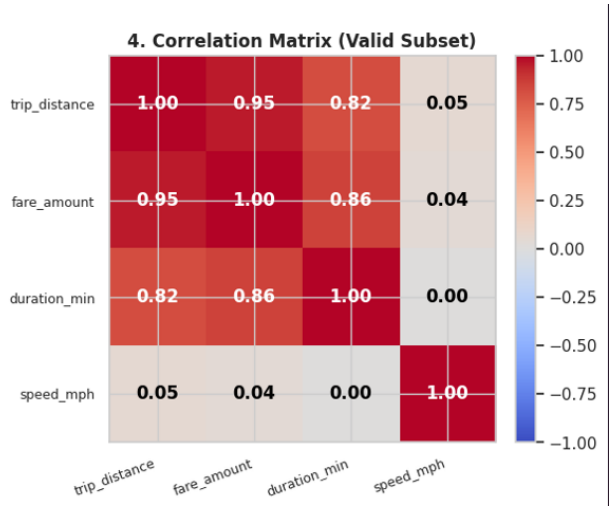
شکل ۹: *
(الف) مسافت سفر در برابر کرایه پایه



شکل ۱۰: *
(ب) مسافت سفر در برابر مدت زمان سفر



شکل ۱۱: *
(ج) توزیع فراوانی سرعت برآوردشده



شکل ۱۲: *
(د) ماتریس همبستگی متغیرهای پیوسته

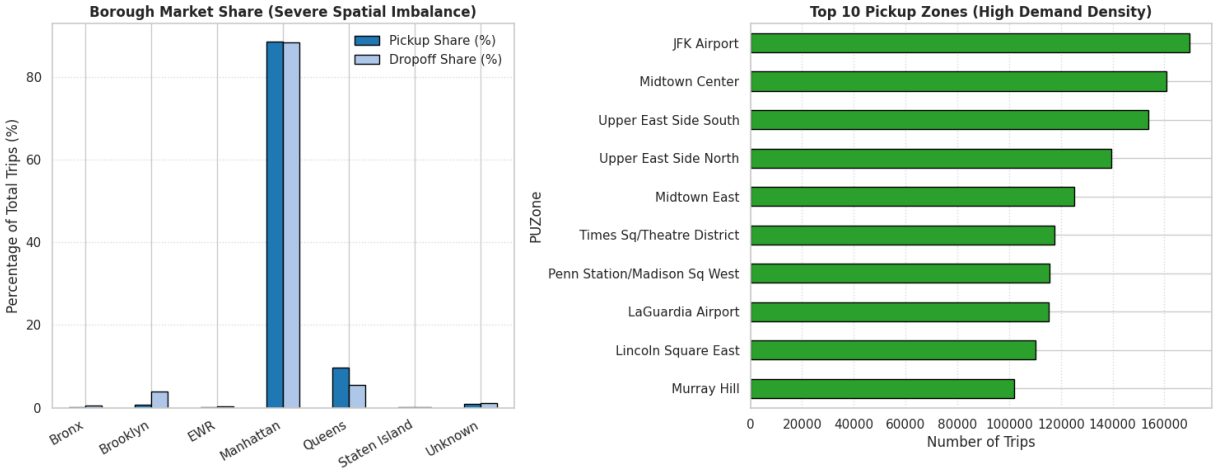
شکل ۱۳: نمودارهای ممیزی سازگاری و تحلیل روابط متقابل متغیرهای سفر

۱۲ تحلیل الگوهای مکانی و بررسی عدم توازن توزیع جغرافیایی

به‌منظور شناخت هندسه تقاضا و بررسی یکنواختی یا چولگی فضایی سفرها، توزیع جغرافیایی مبدأها (PULocationID) و مقاصد (DOLocationID) بر حسب مناطق کلان‌شهری (Borough) و نواحی خرد تاکسی (Taxi Zones) مورد تحلیل آماری قرار گرفت. نتایج این بررسی نشان‌دهنده یک عدم توازن فضایی بسیار شدید (Severe Spatial Imbalance) در شبکه تاکسی‌رانی زردرنگ نیویورک است.

جدول ۵: توزیع فراوانی و سهم بازار مناطق کلان‌شهری نیویورک در جذب و تولید سفر

منطقه کلان‌شهری (**Borough**)	تعداد مبدأ (**Pickup**)	سهم مبدأ (%)	تعداد مقصد (**Dropoff**)	سهم مقصد (%)
Manhattan	3,013,786	88.54	3,010,446	88.44
Queens	327,084	9.61	184,180	5.41
Brooklyn	22,014	0.65	129,893	3.82
Bronx	5,690	0.17	20,565	0.60
Staten Island	292	0.01	1,088	0.03
EWR (فرودگاه نیوآرک)	427	0.01	9,474	0.28
Unknown (نامشخص)	30,908	0.91	35,898	1.05



شکل ۱۴: سهم بازار مناطق کلان‌شهری (نمایانگر تمرکز شدید در منهتن) و ۱۰ ناحیه پرتقاضای مبدأ سفر

نمودارهای به‌دست‌آمده و مقادیر جدول فوق الگوهای رفتاری زیر را آشکار می‌سازند:

- انحصار شدید منهتن در عرضه و تقاضا: منطقه منهتن با اختصاص 88.54% از کل سوارشدن‌ها ($3{,}013{,}786$ سفر) و 88.44% از پیاده‌شدن‌ها ($3{,}010{,}446$ سفر)، هسته اصلی فعالیت تاکسی‌های زردرنگ نیویورک را تشکیل می‌دهد. این انباشتگی شدید نشان می‌دهد که عملکرد تاکسی‌های شهری در عمل محدود به فضای درونی این جزیره است.
- عدم تقارن حرکتی بین مناطق (جریان نامتقارن): مقایسه سهم مبدأ و مقصد در مناطقی نظیر Brooklyn و Queens رفتارهای جالبی را منعکس می‌کند. منطقه Brooklyn تنها 0.65% از سوارشدن‌ها را دارد اما 3.82% از مقاصد به این بخش ختم می‌شوند (بیش از ۵ برابر سهم مبدأ)؛ این امر نشان‌دهنده استفاده از تاکسی زرد برای خروج از منهتن و رجعت به نواحی حاشیه‌ای در ساعات غیرکاری است.
- تمرکز متراکم در گره‌های ترافیکی و فرودگاهی: تحلیل ۱۰ ناحیه پرتقاضای نخست نشان می‌دهد که فرودگاه JFK Airport با جذب $169{,}845$ سفر (4.99%) در رتبه نخست کانون‌های منفرد قرار دارد. پس از آن مناطق تجاری و توریستی مرکز شهر منهتن شامل Midtown Center ($160{,}946$ سفر - 4.73%)، Upper East Side South ($153{,}939$ سفر - 4.52%)، Upper East Side North ($139{,}501$ سفر) و Midtown East ($125{,}220$ سفر) قرار دارند.

توجیه مسئله پژوهش و تمرکز بر دالان منهتن–JFK: این عدم تعادل شدید فضایی اثبات می‌کند آموزش مدل‌های یادگیری ماشین روی کل داده‌های پنج منطقه شهری منجر به بایاس بالا به‌نفع الگوهای محلی درون‌منطقه‌ای منهتن و خطای شدید در پیش‌بینی سفرهای حومه‌ای یا بین‌شهری خواهد شد. از این رو، متمرکز کردن دامنه مدل‌سازی بر دالان ارتباطی حیاتی منهتن به فرودگاه JFK، تصمیمی ساختاریافته در جهت حذف نویز فضایی و ایجاد مدلی عملیاتی با واریانس کنترل‌شده است.

۱۳ سؤال سری‌زمانی و تشخیص الگو (Time-Series Formulation)

- سؤال سری‌زمانی: «الگوی زمانی تقاضای ساعتی سفرها و نوسانات سرعت متوسط بین منهتن و فرودگاه JFK در طول ۲۴ ساعت شبانه‌روز و روزهای هفته چگونه رفتار می‌کند و رخدادهای غیرمعمول (افت ناگهانی سرعت یا جهش تقاضا) در چه ساعت‌هایی رخ می‌دهند؟»
- خروجی مورد انتظار: استخراج چرخه‌های پریودیک روزانه و هفتگی (Seasonality)، تعیین ساعات پیک صبحگاهی و عصرگاهی، و آشکارسازی انحرافات شدید از سرعت نرمال دالان به عنوان رخدادهای غیرمعمول یا شوک ترافیکی.